

ЛЕКЦИЯ 14



ВЫЧИСЛИТЕЛЬНЫЕ СИСТЕМЫ. ПАРАЛЛЕЛЬНЫЕ ВЫЧИСЛЕНИЯ ЧАСТЬ 4

- Когерентность кэш-памяти
- Суперкомпьютеры



Способы обеспечения когерентности кэш-памяти:

- Программные способы (компилятор + ОС)
- Протоколы сквозной записи и обратной записи
- Протоколы записи с аннулированием и записи с обновлением
- Разделяемая кэш-память
- Некэшируемые данные
- Широковещательная запись
- Протоколы наблюдения
- Протоколы на основе справочника
- Стандарт SCI (Scalable Coherent Interface – масштабируемый когерентный интерфейс)

- Согласованность кэша в однопроцессорных ВМ:
 - ☐ Протокол сквозной записи (write through)
 - ☐ Протокол обратной записи (write back)

- В мультипроцессорных ВС копии совместно используемых данных могут находиться сразу в нескольких кэшах и необходимо обеспечить когерентность всех копий

- Ни сквозная, ни обратная запись не предусматривают такой ситуации → применяются другие приёмы:
 - ☐ *Запись с аннулированием* (write invalidate)
 - ☐ *Запись с обновлением* (write update)




- Если какой-либо процессор производит изменения в одном из блоков своей кэш-памяти, все имеющиеся копии этого блока в других локальных кэшах аннулируются, то есть помечаются как недостоверные
- Для этого бит достоверности изменённого блока во всех прочих кэшах устанавливается в 0





- Любая запись в локальный кэш немедленно дублируется и во всех остальных кэшах, содержащих копию изменённого блока (немедленное обновление блока в основной памяти не является обязательным)
- Применяется широковещательная передача новых данных по коммуникационной сети





- Разделяемая кэш-память – формируется единая кэш-память для всех процессоров
 - ❑ Низкая скорость взаимодействия между процессором и кэш-памятью
 - ❑ Арбитраж на каждое обращение к кэш-памяти
- Некэшируемые данные – исключение отдельных видов данных из процесса кэширования, данные передаются в процессоры непосредственно из ОП (например, при управлении критическими секциями)
- Широковещательная запись – информация о каждом изменении данных рассылается в кэш-память всех процессоров



- В системах, где реализованы протоколы наблюдения, контроллер каждой локальной кэш-памяти содержит блок слежения за шиной
- Процессоры широковещательно передают на шину все запросы на доступ к памяти, потенциально способные изменить состояние когерентности совместно используемых блоков данных
- Локальный контроллер кэш-памяти определяет, присутствует ли в его кэш-памяти копия модифицируемого блока, и если это так, то такой блок аннулируется или обновляется




➤ Протокол сквозной записи

➤ Протокол обратной записи

Условия перезаписи в ОП:

☐ Блок удаляется из той кэш-памяти, где он был изменён

☐ Другой процессор обратился к своей копии изменённого блока




Состояния блоков кэш-памяти:

- Недействительный (I, Invalid)
- Достоверный (V, Valid)
- Резервированный (R, Reserved) – однократное изменение, учтённое в ОЗУ
- Изменённый (D, Dirty)




- **Модифицированный** (M, Modified) – данные в блоке кэш-памяти были модифицированы, но изменённая информация пока не переписана в ОП. Информация, содержащаяся в рассматриваемом блоке, достоверна только в данном кэше, а в ОП и остальных кэшах – недостоверна
- **Эксклюзивный** (E, Exclusive) – данный блок в кэш-памяти не подвергался изменению посредством запроса на запись, совпадает с блоком в ОП, но отсутствует в любом другом локальном кэше. Информация достоверна в этой локальной кэш-памяти и недостоверна в любой другой
- **Разделяемый** (S, Shared) – блок в кэш-памяти совпадает с блоком в ОП и может присутствовать в одном или нескольких из прочих кэшей
- **Недействительный** (I, Invalid) – блок кэша не содержит достоверных данных и становится логически недоступным

Протокол MESI



Протокол MESI





- Протоколы на основе справочника предполагают сбор и отслеживание информации о содержимом всех кэш-памятей
- Такие протоколы реализуются с помощью централизованного контроллера в составе ОП
- Справочник хранится в ОП
- Когда контроллер локальной кэш-памяти делает запрос, контроллер справочника обнаруживает такой запрос и формирует команды, необходимые для пересылки данных из ОП либо из другой локальной кэш-памяти, содержащей последнюю версию запрошенных данных
- Центральный контроллер отвечает за обновление информации о состоянии локальных кэш-памятей, поэтому он должен быть извещён о любом локальном действии, способном повлиять на состояние блока данных

Протокол обеспечения
когерентности кэш-памяти
с полным справочником




Протокол обеспечения
когерентности кэш-памяти
со сцепленным справочником





1. Эволюция – экстраполяция предыдущих 20 лет
2. Grid-технологии, облачные вычисления
3. Параллелизм многих уровней схемотехники и программ
4. Сопроцессоры - ускорители; неоднородная структура
5. Обработка на базе ПЛИС – FPGA
6. Специализация на базе заказных микросхем



№	Система, организация, страна	Число ядер	Rmax, PFlop/s	Rpeak, PFlop/s	Энерг., кВт
1	El Capitan - HPE Cray EX255a, AMD 4th Gen EPYC 24C 1.8GHz, AMD Instinct MI300A, Slingshot-11, TOSS, HPE DOE/NNSA/LLNL, United States	11.340.000	1.809	2.821	30
2	Frontier - HPE Cray EX235a, AMD Optimized 3rd Generation EPYC 64C 2GHz, AMD Instinct MI250X, Slingshot-11, HPE, DOE/SC/Oak Ridge National Laboratory, United States	9.066.176	1.353	2.055	24
3	Aurora - HPE Cray EX - Intel Exascale Compute Blade, Xeon CPU Max 9470 52C 2.4GHz, Intel Data Center GPU Max, Slingshot-11, Intel DOE/SC/Argonne National Laboratory, United States	9.264.128	1.012	1.980	39
4	JUPITER Booster - BullSequana XH3000, GH Superchip 72C 3GHz, NVIDIA GH200 Superchip, Quad-Rail NVIDIA InfiniBand NDR200, RedHat Enterprise Linux, EVIDEN EuroHPC/FZJ, Germany	4.801.344	1.000	1.226	16
5	Eagle - Microsoft NDv5, Xeon Platinum 8480C 48C 2GHz, NVIDIA H100, NVIDIA Infiniband NDR, Microsoft Azure, United States	2.073.600	561	846	
6	HPC6 - HPE Cray EX235a, AMD Optimized 3rd Generation EPYC 64C 2GHz, AMD Instinct MI250X, Slingshot-11, RHEL 8.9, HPE Eni S.p.A., Italy	3.143.520	478	607	8
7	Supercomputer Fugaku - Supercomputer Fugaku, A64FX 48C 2.2GHz, Tofu interconnect D, Fujitsu RIKEN Center for Computational Science, Japan	7.630.848	442	537	30
8	Alps - HPE Cray EX254n, NVIDIA Grace 72C 3.1GHz, NVIDIA GH200 Superchip, Slingshot-11, HPE Cray OS, HPE Swiss National Supercomputing Centre (CSCS), Switzerland	2.121.600	435	575	7
9	LUMI - HPE Cray EX235a, AMD Optimized 3rd Generation EPYC 64C 2GHz, AMD Instinct MI250X, Slingshot-11, HPE EuroHPC/CSC, Finland	2.752.704	380	531	7
10	Leonardo - BullSequana XH2000, Xeon Platinum 8358 32C 2.6GHz, NVIDIA A100 SXM4 64 GB, Quad-rail NVIDIA HDR100 Infiniband, EVIDEN EuroHPC/CINECA, Italy	1.824.768	241	306	7,5
83	Chervonenkis - YANDEX Y4N-GA1-TY25-ZB0, AMD EPYC 7702 64C 2GHz, NVIDIA A100 80GB, Infiniband, YANDEX, NVIDIA, Yandex, Russia	193.440	22	30	
115	Galushkin - YANDEX Y4N-GA1-TY25-ZB0, AMD EPYC 7702 64C 2GHz, NVIDIA A100 80GB, Infiniband, YANDEX, NVIDIA, Yandex, Russia	134.912	16	21	
140	Lyapunov - Inspur NF5488A5, AMD EPYC 7662 64C 2GHz, NVIDIA A100 40GB, Infiniband, NVIDIA, Inspur, Yandex, Russia	130.944	13	20	
147	Christofari Neo - NVIDIA DGX A100, AMD EPYC 7742 64C 2.25GHz, NVIDIA A100 80GB, Infiniband, Nvidia, SberCloud, Russia	98.208	12	14.9	
231	Christofari - NVIDIA DGX-2, Xeon Platinum 8168 24C 2.7GHz, Mellanox InfiniBand EDR, NVIDIA Tesla V100 Nvidia, SberCloud, Russia	99.600	7	8.8	

Производительность:

1,809 Eflop/s = 1.809 Pflop/s = 1.809.000 Tflop/s;

Топология: 43 808 24-ядерных AMD 4Gen EPYC 24C + 43 808 GP

AMD Instinct MI300A;

Взаимодействие: Slingshot-11 (12,8 терабит/сек);

Количество ядер:

11.340.000;

Память:

5,4 ПБ ОЗУ (128 ГБ на узел)

Энергопотребление:

29 МВт;

База:

AMD 4th Gen EPYC 24C 1.8GHz;





Производительность:

1,102 Eflop/s = 1.102 Pflop/s = 1.102.000 Tflop/s;

Топология: 9408 узлов: ЦП + 4 ГУ;

Взаимодействие: gigabit ethernet;

Количество ядер:

8.730.112;

Память:

9,2 ПБ ОЗУ

+ 753 ПБ ПЗУ

Энергопотребление:


21 МВт;

База:

AMD 7453 Ерус

+ AMD Instinct MI250X

64С 2ГГц;



Производительность:

1012 Pflop/s;

Топология: **10.624** узлов,

Slingshot 11, Dragonfly;

Пиковая пропускная способность

- внутри узла – **2.12 PB/s**

- между узлами – **0,69 PB/s;**

Количество ядер:

9.264.128;

Память:

10,9 ПБ ОЗУ;

Энергопотребление: 38,7 МВт;



Производительность:

561,2 Pflop/s;

Топология: **1.800** узлов по 8 NVIDIA H100 GPU,
NVIDIA Infiniband NDR;

Количество ядер:

1.123.200;


Память:

10,9 ПБ ОЗУ;

Энергопотребление: **24,6 МВт;**



8x H100 NVIDIA GPU System





Производительность:

415,5 Pflop/s;

Топология: 159.000 узлов;

Количество ядер:

7.630.848;


Память:

32 ГБ ОЗУ на узел

+ 1,6 ТБ SSD на 16 узлов

Энергопотребление: 28 МВт;

- Fujitsu A64FX: 48 ядер





Производительность: **148,6 Pflop/s (200,8 Pflop/s)**;
Топология: Non-blocking Fat Tree;
Взаимодействие: Dual-rail Mellanox EDR Infiniband;
Количество ядер:
2.414.592;
Память:
2,8 ПБ DDR4;
Энергопотребление:
10 МВт (13 МВт);
База: IBM POWER9
22С 3.07ГГц;





Производительность: **93 Pflop/s (125,4 Pflop/s);**

Топология: MPP; Взаимодействие: Sunway;

Количество ядер: 10.649.600; Энергопотребление: 15,4МВт; Память: 1,3 ПБ;

База: Sunway SW26010 260C 1.45GHz





Производительность: **21,53 Pflop/s (8,8 Pflop/s);**


Взаимодействие: InfiniBand EDR;

Топология: 199 узлов;

Количество ядер:

193.440;

База: AMD EPYC + NVIDIA A100;





Производительность: **6,7 Pflop/s (8,8 Pflop/s);**

Взаимодействие: Mellanox InfiniBand EDR;

Количество ядер:

99.600;

Память:

115 ТБ DDR4;

База: Xeon Platinum

8168 24C 2.7GHz;





- Задержки и ограниченная пропускная способность интерфейса «процессор-память», межпроцессорных коммуникаций и средств ввода-вывода
- Издержки со стороны ОС и коммуникационных программ, нарастающие с увеличением количества процессоров
- Трудности распараллеливания вычислений для полной загрузки обрабатываемых ресурсов, усугубляемые неоднородностью структур и средств
- Недостаточная поддержка параллельных вычислений со стороны языков программирования и др. средств
- Недооценка работ по анализу и оптимизации прикладных программ и потоков обработки
- Необходимы дальнейшие работы по созданию проблемно-ориентированных суперкомпьютеров