

Проверка гипотезы однородности

Пусть элементы независимых выборок $(x_1, \dots, x_k)$ и $(y_1, \dots, y_n)$ имеют теоретические функции распределения $F_1(z)$ и $F_2(z)$, соответственно.

Гипотезы:

$$H_0: F_1(z) = F_2(z);$$

$$H_1: F_1(z) \neq F_2(z).$$

Верна гипотеза $H_0 \Leftrightarrow$ выборки $(x_1, \dots, x_k)$ и $(y_1, \dots, y_n)$ произведены из одной и той же генеральной совокупности.

Такие гипотезы проверяются *критериями однородности выборок*.

Критерий знаков

Критерий знаков (sign test) проверяет гипотезу
«Выборка имеет биномиальное распределение
с вероятностью успеха $p = \frac{1}{2}$ ».

Задачи, решаемые с использованием критерия

знаков:

1. При n испытаниях Бернулли успех произошел t раз.

Монета симметричная?

В выборке $(x_1, \dots, x_n), x_i \in \{0, 1\}$, — t единиц и $n - t$ нулей.

$$H_0: P\{\xi = 1\} = \frac{1}{2} \text{ (простая).}$$

Варианты альтернативных гипотез:

$$H_1': P\{\xi = 1\} \neq \frac{1}{2};$$

$$H_1'': P\{\xi = 1\} < \frac{1}{2};$$

$$H_1''': P\{\xi = 1\} > \frac{1}{2}.$$

Статистика критерия:

$$b_{\text{набл}} = b(x_1, \dots, x_n) = \sum_{k=0}^t C_n^k \left(\frac{1}{2}\right)^k \left(1 - \frac{1}{2}\right)^{n-k} = \frac{1}{2^n} \sum_{k=0}^t C_n^k.$$

При заданном уровне значимости α гипотезу H_0 отвергаем, если:

$b_{\text{набл}} \notin [\alpha/2, 1 - \alpha/2]$ (при H_1' , двусторонняя критическая область);

$b_{\text{набл}} < \alpha$ (при H_1'' , левосторонняя критическая область);

$b_{\text{набл}} < 1 - \alpha$ (при H_1''' , правосторонняя критическая область).

2. Для данного значения $a \in \mathbb{R}$ по выборке $(x_1, \dots, x_n)$,
где $x_i \in \mathbb{R}$, проверить

$$H_0: P\{\xi < a\} = \frac{1}{2}.$$

Значение a — медиана распределения с.в. ξ .

Пусть $b_i = 1$ при $x_i < a, i = 1, \dots, n$ (значения $x_i = a$,
исключаем) $\Rightarrow$ получили п.1.

3. Пусть $(x_1, \dots, x_n)$, где $x_i \in \mathbb{R}$, — значения измерений некоторой характеристики до обработки, $(y_1, \dots, y_n)$, где $y_i \in \mathbb{R}$, — значения измерений той же характеристики после обработки — **связные выборки**. Является ли обработка эффективной?

Основная гипотеза

$$H_0: P\{\xi < \eta\} = \frac{1}{2}.$$

Пусть $b_i = 1$ при $x_i < y_i, i = 1, \dots, n$ (значения $x_i = y_i$ исключаем) $\Rightarrow$ получили п.1.

Для $i = 1, \dots, n$: “+” при $x_i < y_i$, “-” при $x_i \geq y_i$. Число
“+” (число “-”) $\approx n/2$.

Ранговый критерий

Из $(x_1, \dots, x_k)$ и $(y_1, \dots, y_n)$ составим вариационный ряд.

Ранги $r_1, \dots, r_k$ — порядковые номера элементов выборки $(x_1, \dots, x_k)$.

Если есть элементы с одинаковым значением, то значению приписывается среднее арифметическое рангов.

Критерии, позволяющие только на основе рангов $r_1, \dots, r_k$ принимать или отвергать гипотезу H_0 об однородности двух выборок — **ранговые**.

Если справедлива H_0 , то все возможные комбинации рангов равновероятны, $\Rightarrow$ уровень значимости критерия не зависит от распределения выборок.

Статистика критерия –

$$f(r_1) + \dots + f(r_k),$$

где $f(r)$ – функция, определенная для всех
 $r = 1, 2, \dots, k + n$.

Критерий Уилкоксона (Wilcoxon)

Пусть $(s_1, \dots, s_{k+n})$ — одна из $(k+n)!$ возможных перестановок чисел $1, 2, \dots, k+n$.

Статистика критерия

$$W_{\text{набл.}} = s_{r_1} + \dots + s_{r_k},$$

т.е. $f(r) = s_r$.

Односторонний критерий Уилкоксона

(левосторонняя критическая область): принимается

гипотеза H_0 , если $w_{\text{набл.}} > w_{\text{нижн.кр.}}$.

Двусторонний критерий Уилкоксона: принимается

гипотеза H_0 , если $w_{\text{нижн.кр.}} < w_{\text{набл.}} < w_{\text{верхн.кр.}}$, где

$$w_{\text{нижн.кр.}} + w_{\text{верхн.кр.}} = (k + n + 1)k.$$

Выбор перестановки $(s_1, \dots, s_{k+n})$

1) $s_r = r$

- ✓ если «плохо» — принять H_0 , когда $F_1(z) < F_2(z)$ при всех z , то односторонний критерий;
- ✓ если «плохо» — принять H_0 , и когда $F_1(z) < F_2(z)$ при всех z , и когда $F_2(z) < F_1(z)$ при всех z , то двусторонний критерий.

$$2) \quad s_1 = 1, s_{k+n} = 2, s_{k+n-1} = 3, s_2 = 4, s_3 = 5,$$

$$s_{k+n-2} = 6, \dots$$

Известно, что $E\tilde{\xi}_1 = E\tilde{\xi}_2$.

Гипотезы:

H_0 : разброс случайных величин одинаков;

H_1 : разброс первой величины больше разброса второй.

Если верна основная гипотеза $H_0: F_1(z) = F_2(z)$, то распределение статистики критерия Уилкоксона зависит только от k и n и не зависит от перестановки $(s_1, \dots, s_{k+n})$.

Уровень значимости одностороннего критерия

для $w_{кр.}$:

$$\alpha = \frac{\#\{(r_1, \dots, r_k) \mid r_1 + \dots + r_k \leq w_{кр.}\}}{C_{k+n}^k}.$$

Уровень значимости двустороннего критерия =
удвоенный уровень значимости одностороннего
критерия с $w_{кр.} = w_{нижн.кр.}$

Пример 1. При уровне значимости $\alpha = 0,01$ проверить гипотезу об однородности выборок объемов $k = 6$ и $n = 7$:

x_i	4	5	7	9	12	15	
y_i	1	2	6	10	14	18	20

Общий вариационный ряд:

1	2	<u>4</u>	<u>5</u>	6	<u>7</u>	<u>9</u>	10	<u>12</u>	14	<u>15</u>	18	20
---	---	----------	----------	---	----------	----------	----	-----------	----	-----------	----	----

Статистика критерия:

$$w_{\text{набл.}} = 3 + 4 + 6 + 7 + 9 + 11 = 40.$$

По таблице:

$$w_{\text{нижн.кр.}}(\alpha/2; k, n) = w_{\text{нижн.кр.}}(0,005; 6, 7) = 24.$$

Верхняя критическая точка:

$$w_{\text{верхн.кр.}} = (6 + 7 + 1) \cdot 6 - 24 = 60.$$

$24 < 40 < 60 \Rightarrow$ принимаем H_0 .

Замечание 1. В среднем статистика должна быть
примерно равна $\frac{(k+n+1)k}{2}$.

Замечание 2. Если объем хотя бы одной из выборок больше 25, то считают, что статистика критерия Уилкоксона распределена нормально:

$$N\left(\frac{(k+n+1)k}{2}, \frac{(k+n+1)kn}{12}\right),$$

при заданном уровне значимости α критические границы:

для левостороннего критерия

$$W_{\text{нижн.}} = \frac{(k+n+1)k}{2} - \phi_{\alpha} \sqrt{\frac{(k+n+1)kn}{12}},$$

для двустороннего критерия

$$W_{\text{нижн., верхн.}} = \frac{(k+n+1)k}{2} \pm \phi_{\frac{\alpha}{2}} \sqrt{\frac{(k+n+1)kn}{12}}.$$

Критерий Смирнова

Для выборок $(x_1, \dots, x_k)$ и $(y_1, \dots, y_n)$ статистика:

$$\rho = \sqrt{\frac{kn}{k+n}} \sup |\hat{F}_1(z) - \hat{F}_2(z)|,$$

где $\hat{F}_1(z), \hat{F}_2(z)$ — эмпирические функции
распределения выборок $(x_1, \dots, x_k)$ и $(y_1, \dots, y_n)$
соответственно.

При $k, n \leq 20$ критические значения d — по таблицам (принимая H_0 , если $\rho \leq d$). При больших объемах выборки статистика ρ имеет распределение Колмогорова, уровень значимости определяется как $\alpha = 1 - K(d)$:

$$\forall d > 0 \quad \lim_{k, n \rightarrow \infty} P\{\rho \leq d\} = K(d) = \sum_{j=-\infty}^{+\infty} (-1)^j e^{-2j^2 d^2}.$$

Пример 2. Проведено два сходных эксперимента, в результате которых получены выборки объемов $k = 631, n = 839$. После построения эмпирических функций распределения вычислено значение

$$\sup |\hat{F}_1(z) - \hat{F}_2(z)| = 0,042.$$

Проверим с помощью критерия Смирнова для $\alpha = 0,1$ гипотезу об одинаковом распределении выборок.

$$\rho = \sqrt{\frac{kn}{k+n}} \sup |\hat{F}_1(z) - \hat{F}_2(z)| = 0,8,$$

$$K(d) = 1 - \alpha = 0,9,$$

$$d = 1,22.$$

$$\rho < d \Rightarrow \text{принимаем } H_0.$$