

Регрессионный анализ

Пусть (ξ, η) — дискретная с.в.,

$$\xi \leftrightarrow x_1, x_2, \dots, x_n, \quad \eta \leftrightarrow y_1, y_2, \dots, y_m.$$

Значение условного м.о.

$$\mathbf{E}(\xi \mid \eta = y_j) = \sum_{i=1}^n x_i \pi_{ij}.$$

Условное м.о. с.в. ξ относительно с.в. η :

$$\mathbf{E}(\xi \mid \eta) = g(\eta),$$

при этом $g(y_j) = \mathbf{E}(\xi \mid \eta = y_j)$.

Зависимость ξ от η характеризуется функцией

$$g(y) = \mathbf{E}(\xi \mid \eta = y)$$

— **регрессия** (от лат. regressio — обратное движение) с.в. ξ на с.в. η ; ее график — **линия регрессии** ξ на η .

Явление описывается параметром $x = x(t)$,

где t — время,

$$x(t) = \theta_1 f_1(t) + \dots + \theta_k f_k(t),$$

f_i — известные функции,

θ_i — неизвестные параметры.

В моменты $t_1, \dots, t_n$ параметр $x(t)$ измеряется
с ошибками $\varepsilon_1, \dots, \varepsilon_n$ (независимые, $\sim N(0, \sigma^2)$).

Результаты измерений:

$$X_i(t) = \theta_1 f_1(t_i) + \dots + \theta_k f_k(t_i) + \varepsilon_i.$$

Задачи:

1. Найти оценки параметров $\theta_1, \dots, \theta_k$,
построить для них доверительные интервалы.

2. Проверить гипотезу: некоторые θ_j равны 0.

3. Найти оценку $\hat{x}(t)$ регрессии $x(t)$ в произвольный момент времени t , построить для нее доверительный интервал.

Ограничения:

1) число наблюдений n больше

числа параметров k ;

2) векторы $\vec{f}_i = (f_i(t_1), \dots, f_i(t_n))$, $i = 1, \dots, k$, —

линейно независимые.

Решение задачи 1 (Найти оценки для $\theta_1, \dots, \theta_k$

и построить доверительные интервалы.)

А. Построение точечных оценок.

Минимизируем функцию

$$S^2 = S^2(\theta_1, \dots, \theta_k) = \sum_{i=1}^n \left(X_i - \sum_{j=1}^k \theta_j f_j(t_i) \right)^2.$$

$$X_i(t) = \theta_1 f_1(t_i) + \dots + \theta_k f_k(t_i) + \varepsilon_i.$$

Дифференцируем по $\theta_j \Rightarrow$

$$\hat{\theta}_1 \sum_{i=1}^n f_j(t_i) f_1(t_i) + \dots$$

$$+ \hat{\theta}_k \sum_{i=1}^n f_j(t_i) f_k(t_i) = \sum_{i=1}^n X_i f_j(t_i).$$

Оценки $\hat{\theta}_j$:

1) линейные от $X_1, \dots, X_n$, — $\hat{\theta}_j = \sum_{i=1}^n c_{ij} X_i$, —

нормально распределенные;

Оценки $\hat{\theta}_j$:

2) эффективные, в т.ч. несмещенные
с минимальной возможной дисперсией.

Б. Построение доверительных интервалов.

Симметричные доверительные интервалы

доверительной вероятности $1 - \gamma$:

$$\theta'_j = \hat{\theta}_j - t_{1-\frac{\gamma}{2}} \sqrt{c_j^2 s_0^2}, \quad \theta''_j = \hat{\theta}_j + t_{1-\frac{\gamma}{2}} \sqrt{c_j^2 s_0^2},$$

где

t_α — α -квантиль распределения Стьюдента

с $n - k$ степенями свободы,

$$s_0^2 = \frac{1}{n-k} \min_{\theta_1, \dots, \theta_k} S^2(\theta_1, \dots, \theta_k) = \frac{S^2(\hat{\theta}_1, \dots, \hat{\theta}_k)}{n-k},$$

$$c_j^2 = \sum_{i=1}^n c_{ij}^2.$$

Если $\vec{f}_i$ ортогональны, т.е.

$$\sum_{j=1}^l f_i(t_j)f_k(t_j) = 0, \quad k \neq j,$$

то

$$\hat{\theta}_j \sum_{i=1}^n (f_j(t_i))^2 = \sum_{i=1}^n X_i f_j(t_i),$$

$\Rightarrow$ оценки $\hat{\theta}_j$ — независимые.

Решение задачи 2 (Проверить гипотезу о том,

что некоторые θ_j равны 0.)

Гипотеза:

$$H_0: \theta_{k'+1} = \dots = \theta_k = 0, \text{ где } 0 \leq k' < k.$$

Определим

$$s_0^2 = \frac{1}{n - k} \min_{\theta_1, \dots, \theta_k} S^2(\theta_1, \dots, \theta_k),$$

$$s_2^2 = \min_{\theta_1, \dots, \theta_{k'}} S^2(\theta_1, \dots, \theta_{k'}, 0, \dots, 0).$$

Положим

$$\hat{s}_1^2 = \frac{s_2^2 - (n - k)\hat{s}_0^2}{k - k'},$$

$$\eta = \frac{\hat{s}_1^2}{\hat{s}_0^2}.$$

Для уровня значимости α :

H_0 — при $\eta < \varphi_{1-\alpha}$,

где φ_α — α -квантиль распределения Фишера

с параметрами $k - k'$ и $n - k$.

Распределение Фишера:

если с.в. χ_1^2 и χ_2^2 — независимые,

$\chi_1^2 \sim \chi^2(n_1)$, $\chi_2^2 \sim \chi^2(n_2)$, то $\eta = \frac{n_2 \chi_1^2}{n_1 \chi_2^2} \sim F(n_1, n_2)$,

$$\psi(x) = \frac{\Gamma\left(\frac{n_1+n_2}{2}\right)}{\Gamma\left(\frac{n_1}{2}\right)\Gamma\left(\frac{n_2}{2}\right)} n_1^{\frac{n_1}{2}} n_2^{\frac{n_2}{2}} x^{n_1 \frac{n_1}{2}-1} (n_2 + n_1 x)^{-\frac{n_1+n_2}{2}},$$

$$x > 0.$$



**Сэр Рональд
Эйлмер Фишер
(1890—1962) —
англ. статистик,
биолог-
эволюционист,
генетик**

Решение задачи 3 (Найти оценку $\hat{x}(t)$

регрессии $x(t)$ в произвольный момент времени

t и построить для $x(t)$ доверительный

интервал.)

А. Построение точечной оценки.

Подставляем в $x(t)$ вместо θ_j оценки $\hat{\theta}_j$:

$$\hat{x}(t) = \hat{\theta}_1 f_1(t) + \dots + \hat{\theta}_k f_k(t)$$

— нормально распределенная, несмещенная,
эффективная.

Б. Построение доверительного интервала.

$$\hat{\theta}_j = \sum_{i=1}^n c_{ij} X_i,$$

$$\begin{aligned}\hat{x}(t) &= \sum_{j=1}^k \hat{\theta}_j f_j(t) = \sum_{j=1}^k \left(\sum_{i=1}^n c_{ij} X_i \right) f_j(t) = \\ &= \sum_{i=1}^n \left(\sum_{j=1}^k c_{ij} f_j(t) \right) X_i = \sum_{i=1}^n \delta_i X_i.\end{aligned}$$

$$\begin{aligned}\mathbf{D}\hat{x}(t) &= \sum_{i=1}^n \mathbf{D}(\delta_i X_i) = \sum_{i=1}^n \delta_i^2 \mathbf{D}X_i = \\ &= \sigma^2 \sum_{i=1}^n \left(\sum_{j=1}^k c_{ij} f_j(t) \right)^2 = \sigma^2 c^2(t).\end{aligned}$$

$\Rightarrow$

$$\frac{\hat{x}(t) - x(t)}{\sqrt{\sigma^2 c^2(t)}} \sim N(0,1).$$

Статистика $\hat{s}_0^2$ не зависит от $\hat{x}(t)$,

$$\mathbf{D}\hat{s}_0^2 = \sigma^2,$$

поэтому

$$\tau = \frac{\hat{x}(t) - x(t)}{\sqrt{c^2(t)\hat{s}_0^2}} \sim t(n - k).$$

Границы симметричного интервала

доверительной вероятности $1 - \gamma$:

$$x'(t) = \hat{x}(t) - t_{1-\frac{\gamma}{2}} \sqrt{c^2(t) \hat{s}_0^2},$$

$$x''(t) = \hat{x}(t) + t_{1-\frac{\gamma}{2}} \sqrt{c^2(t) \hat{s}_0^2}.$$

Выбор функций $f_j(t)$:

- ✓ линейная регрессия: $x(t) = \theta_1 + \theta_2 t$;
- ✓ квадратичная регрессия: $x(t) = \theta_1 + \theta_2 t + \theta_3 t^2$;
- ✓ экспоненциальная регрессия: $x(t) = \theta_1 + \theta_2 e^{at}$.